

研究问题

预训练开放词汇 VLM 能否作为目标定位前端，提升二维抓取矩形检测？

核心思路：保持定位前端一致，对比传统几何后端与学习式 CNN 后端。

数据集

885 个样本

定位覆盖


885 / 885

成功判定

$\text{IoU} \geq 0.25$

角度条件

误差 $\leq 30^\circ$



VLM 定位与抓取预测示例

三条实验流程

1

传统 CV 基线

完整 RGB 图像



阈值分割与轮廓



最小面积旋转矩形

2

VLM + 几何

Grounding DINO 定位



定位区域内分割



几何抓取矩形

3

VLM + CNN

Grounding DINO 定位



224×224 RGB 裁剪



回归 6 个抓取参数

完整 Cornell 数据集（885 个样本）

方法	成功率	平均最佳 IoU	平均角度误差
传统 CV	56.95%	0.3360	29.62°
VLM + 几何	73.33%	0.4182	14.81°
VLM + CNN（5 次）	74.51% ± 1.38%	0.4510 ± 0.0081	16.49° ± 0.72°

未见物体测试集（85 个样本）



失败案例分析

126 / 236

失败样本角度正确，
主要问题是位置或尺寸不准。

→ 这直接支持引入学习式抓取后端。

关键结论

+16.38 个百分点

VLM 定位带来最大提升

56.95% → 73.33%

更高 IoU 与泛化

CNN 改善位置和尺寸

测试集 82.35% ± 4.53%

14.81°

几何后端角度更准

显式方向先验仍然有效

已完成



三条实验流程

传统 CV、VLM + 几何、VLM + CNN



全量评估

Cornell 885 个样本，统一矩形指标



稳定性验证

CNN 使用 5 个随机种子重复实验



失败案例分析

236 个失败样本按 IoU 与角度分类

下一步

1

完成论文主体

Introduction、Methodology、Results、Discussion

2

整理实验图表

方法对比、失败分布、成功与失败示例

3

补充逐样本分析

重点分析 CNN 的位置、尺寸与角度误差

4

可选混合后端

CNN 回归位置与尺寸，几何方法提供角度先验

当前局限

- 目前只在 Cornell 数据集上进行离线二维评估
- 未执行真实机械臂控制或闭环抓取
- 885 / 885 表示当前设置下有检测输出，不等于定位框完全准确

关键论文依据

1. Liu et al. (2023), Grounding DINO：开放集目标检测
2. Morrison et al. (2018), GG-CNN：实时生成式抓取预测，并使用 $\sin(2\theta)$ 、 $\cos(2\theta)$ 表示平行夹爪角度

阶段结论：VLM 已有效解决目标区域定位；下一阶段重点是抓取后端优化与论文整理。